Occam — 出所の棚卸し

2026-10-16 ／ どの機構が誰のもので、どこからがここで組んだものか

> **新規性の主張ではない。**先行技術調査は含まない。引用すべき相手を取り違えないための、出所の地図。

先に書いておくこと。

— **先行技術調査をしていない。**各項目について「既にある」可能性を否定できない

— 「公知」欄は**このリポジトリが出典として記録しているもの**で、調査結果ではない

— 新規性の主張ではない。**引用すべき相手を取り違えないための地図**

0. 全探索の範囲

Python	**35本（製品経路14本、計測・記録9本、取り込み13本、降格3本）**
Rust	5本（`engine/`）
ロック	KeepOut 9箇所
文書	HANDOFF（§0〜§14）、prompt_format、overbuilt、本書

1. まず「人のもの」を外す

ここを混ぜると相談が成立しない。

技術	出典	本プロジェクトの立場
eNTRy 則（イオン化可能窒素 / globularity / 回転結合≤5）	**Richter et al., Nature 545:299 (2017)**、Hergenrother ラボ	**適用しているだけ。**`knobs.py` の設定は全部これ
MW < 600 Da	O'Shea & Moser 2008 J Med Chem 51:2871（Richter 2017 が逐語引用）	適用。しかも**二次出典**と記録済み
HyperLogLog	公知のアルゴリズム	実装しているだけ
Butina クラスタリング	公知。RDKit 実装	呼んでいるだけ
Morgan / ECFP 指紋	公知。RDKit 実装	呼んでいるだけ
Tanimoto 0.4〜0.6 の適用範囲判定	**業界標準の実務**	閾値もその帯から採っている
ヒストグラム GBDT / オンライン logistic regression	公知（LightGBM 等）	実装しているだけ
Murcko scaffold	公知	呼んでいるだけ
ZINC22 の tranche 構造・電荷サフィックス	ZINC の仕様	読んでいるだけ

データも全部他人のもの。CHAMP（CC BY 4.0）、GramNegAccum（CC BY 4.0）、

IMI-COMBINE（MIT）、B3DB、ZINC22（再配布に許可要）。

→ 個々の要素技術に主張できるものは無い。残るのは構成と機構。

2. 機構 A：有界メモリの処理機構（最も「技術的効果」の形をしている）

何か

ストリーム処理で、**作業メモリがデータ量から独立する**ことを型と所有権で強制する構造。

```
// engine/src/main.rs [LOCK]
for bulk in &mut bulks {
    let bulk = bulk?;
    let mut op = DomainOperator::new(pass, args.learning_rate);
    carry = op.absorb(&bulk, carry);
    // op and bulk are dropped here, before the next iteration
}
```

3つの不変条件で成立している。

	内容	実装箇所
1	**バルクを同時に2つ持たない。**読み手は返したバルクへの参照を保持せず、先読みしない	`bulk.rs` [LOCK]×2
2	**オペレータ間を生き延びるのは carry だけ**で、そのサイズはコンパイル時固定（`[Candidate; K]`、`[f32; W]`、`[[u32; BINS]; 2]`）	`carry.rs` [LOCK]
3	**演算器とバルクを同時に1つしか持たない。**次の反復の前に drop される	`main.rs` [LOCK]、`process.rs` [LOCK]

実測

D軸（バルク固定、データ量 62倍）	ピーク RSS +2.59%
B軸（データ量固定、バルク 256倍）	固定費 34 MiB が一定
1万倍	**−2.7%**（データ/RSS = 73倍、2048次元・実データ・100万件）
代償	AUC **−0.0001**

主張できそうな形

「有界メモリであること」ではない（それは公知の性質）。**それを静的に強制し、破れたら検出する機構**の方。

— 所有権と drop 順で不変条件を型レベルに落とす構成

— **AST ロック（KeepOut）で不変条件を守るコード領域を機械的に封じる。**整形・コメント・変数改名は無視し、構造変更だけを拒否する

— テストが不変条件そのものを検査する（2軸、因子を環境変数で振る）

製品経路にいる（2026-10-12 に訂正）

`py/screenable.py` の `rankability()` が `engine/target-fp/release/engine` を subprocess で起動し、順位付けの可否を判定している。**エンジンは製品の一部。**

前日の棚卸しで「製品は呼ばない」と書いたのは、文字列検索の誤り（パス結合で書かれていて `engine/target` という文字列が現れない）。

特許の相談としては、こちらの方が強い。使われていない機構ではなく、製品が通る経路の機構である。

弱点

— ストリーム処理で有界メモリ、は一般的な設計。**「強制する」部分が差分**

— `[LOCK]` コメント ＋ AST ハッシュという方式自体に類例があるか、私は調べていない

— 言語機能（Rust の所有権）に依存した主張は、言語を変えると成立しない

3. 機構 B：実行前に要求を拒否する検問機構（構成として最も特徴的）

何か

スクリーニング要求を、1分子も読む前に、公表規則との整合で止める機構。

検査	内容	実装
スライス矛盾	要求が「イオン化可能窒素」を含み、ライブラリが pH 7.4 中性と予測されるスライスなら停止。**公表データ（陽性12/41 対 中性0/39）を根拠として出す**	`provenance.py`
障壁不一致	条件がグラム陰性外膜の規則で、ライブラリが血液脳関門を測っているなら停止	`occam.py` + `knobs.APPLIES_TO`
語彙外を丸めない	MW 500 は 450 に寄せず停止。登録値を列挙して返す	`occam.py` NUMERIC
別の量への読み替えを拒否	「電荷」は引退した knob。スライス選択に黙って回さず停止	`occam.py` CHARGE_WORDS
事実の主張を破棄	入力中の件数・AUC・骨格数は要求ではないので捨て、理由付きで一覧	`occam.py` FACT_CLAIMS
標的の不在	ラベルが存在しない標的は `cannot be answered` ＋ 実測の代替案	`feasible.py` + `screenable.py`
スコープ不一致	第1パスと第2パスが違う量を読んでいたら停止	`propose.py`
不可能な計数	骨格数 > 生存数 なら落ちる	`propose.py`

主張できそうな形

**「要求と、参照する公表規則と、データの出自を突き合わせ、実行前に矛盾を検出して

停止する」という構成。**個々の検査ではなく、**検問所として閉じていること。**

弱点

— 入力検証そのものは普遍的。**「公表規則との照合」が差分だが、規則は他人のもの**

— 自然言語処理を使わない決定的照合（閉じた語彙）は、むしろ単純な実装

— ビジネスメソッド寄りに見られる可能性（法域による）

4. 機構 C：出自型付きの緩和と frontier（重み付きスコアを使わない）

何か

各設定に**出自の型**を持たせ、緩和の提案を型で制約する。

```
published     公表規則が既に言っている範囲内の置換（新しい化学的主張をしない）
relaxation    数値閾値を動かしただけ（主張が元から無い）
unjustified   新しい化学的主張。提案してはならない
```

そのうえで、**重み付きスコアで1つに決めず、条件を満たす仕様を全部返す。**

```
score = w1×生存 + w2×多様性 − w3×penalty    ← 使わない
```

理由：w は発明物で、「最良」が重みの産物になる。順序は

（緩和ステップ数、出自、決定的タイブレーク）の辞書式のみ。

主張できそうな形

**「提案の各要素に出自の型を付け、型が許す範囲でのみ緩和を生成し、

単一解ではなく充足解の集合を返す」**構成。監査が1行で済むこと（論文が言っているか、

数字を動かしただけか）が効果。

弱点

— 多目的最適化で Pareto frontier を返すのは公知

— 「出自を記録する」はデータ来歴（provenance）の一般論

— **組み合わせが差分**だが、進歩性があるかは私には判断できない

5. 機構 D：拒否を測定要件に変換する機構

何か

適用範囲外という判定を、**測定すべき化合物数**に変換する。

```
適用範囲の検定     各化合物に閾値内の訓練近傍があるか
        ↓ 同じ閾値で
クラスタリング     近傍を持たない領域 = 1クラスタ
        ↓
出力                  クラスタ数 = 測るべき化合物数、被覆曲線、閾値感度
```

実測例：307件が範囲外 → **268件測れば全被覆、115件で半分。**

主張できそうな形

「適用範囲判定の閾値と同じ閾値でクラスタリングし、クラスタ数を測定要件として返す」

という変換。拒否で終わらず、拒否を解消する実験計画の規模を出す。

弱点

— クラスタリングによる代表化合物選定（diverse subset selection）は**創薬で極めて一般的**

— 適用範囲の判定も標準

— **「同じ閾値を使う」という結び方が差分だが、自明と見られる可能性が高い**

私の見立てでは、A〜D のうちこれが一番弱い。ただし現場価値は一番高い。

6. 機構 E：対照付きの判定

何か

重い判定（適用範囲外、inert）に、**同じ測定を訓練集合内で回した対照**を必ず添える。

```
predicting activity: can be answered only by extrapolating
  median 0.212 against a 0.4 threshold
  positive control: passes
    the same measurement run inside the training set gives median 0.747,
    with 94.0% at or above the threshold
    this rules out: a fingerprint radius or bit-length mismatch, or salts
    and stereochemistry left on one side
```

理由：`out_of_domain` **と「計算が壊れている」は同じ顔をする**（禁忌79）。

主張できそうな形

「判定の出力に、同一の計算経路を既知陽性集合に適用した結果を強制的に併記する」機構。

弱点

— 陽性対照は実験科学の基本。**計算に持ち込んだだけ、と見られる**

— ただし「強制」（対照なしでは出力しない）が構成要素になるかは弁理士の判断

7. 使う前に知っておくべきこと

1. KeepOut は Apache-2.0 で、このリポジトリと同じ著者・同じライセンス。

`third_party/keepout/` に vendor してある

2. ZINC22 の開放世代のみを使用（`data/raw/zinc22/manifest.json` に記録）。

再配布には書面許可が要るので、このリポジトリは SMILES を同梱せず、

tranche 名と取得手順だけを持つ

3. eNTRy は Hergenrother ラボの公表成果。適用しているのであって競合ではない

4. 外部検証がゼロ。他人が一度も回していない

5. 実験を一度もしていない。細胞に触っていない